



GABRIEL DO AMARAL DE OLIVEIRA

**MACHINE LEARNING: ASSISTENTE MÓVEL PARA
RECONHECIMENTO DE EXPRESSÕES FACIAIS EM APOIO A PESSOAS
COM TEA**

CAMPINAS
2026

GABRIEL DO AMARAL DE OLIVEIRA

**MACHINE LEARNING: ASSISTENTE MÓVEL PARA RECONHECIMENTO DE
EXPRESSÕES FACIAIS EM APOIO A PESSOAS COM TEA**

Trabalho de Conclusão de Curso apresentado
como parte dos requisitos para obtenção do
diploma do Curso Tecnologia em Análise e
Desenvolvimento de Sistemas do Instituto
Federal de Educação, Ciência e Tecnologia de
São Paulo - Campus Campinas.

Orientador: Prof. Dr. Ricardo Barz Sovat.

CAMPINAS
2026

FICHA CATALOGRÁFICA

Biblioteca IFSP – Campus Campinas Tatiane
Helena Borges de Salles
CRB8/8946

Oliveira, Gabriel do Amaral de.

Machine Learning: Assistente móvel para reconhecimento de expressões faciais em apoio a pessoa com TEA : / Gabriel do Amaral de Oliveira. – 2025. 21 f. il.

Trabalho de Conclusão de Curso (Graduação em Tecnologia em Análise e Desenvolvimento de Sistemas) – Instituto Federal de Educação, Ciência e Tecnologia do Estado de São Paulo, Campinas, SP, 2026 .

Orientador(a): Ricardo Barz Sovat.

1. Transtorno do espectro autista. 2. Reconhecimento facial (Computação). 3. Aprendizado de máquina. 4. Tecnologia assistiva. 5. iOS (Recurso eletrônico). I. Orientador(a) Ricardo Barz Sovat. II. Instituto Federal de Educação, Ciência e Tecnologia de São Paulo. III. Título.

ATA N.º 6/2026 - TADS-CMP/DAE-CMP/DRG/CMP/IFSP

Ata de Defesa de Trabalho de Conclusão de Curso - Graduação

Na data de 15 de maio de 2026 realizou-se a sessão pública de defesa do Trabalho de Conclusão de Curso intitulado **MACHINE LEARNING: ASSISTENTE MÓVEL PARA RECONHECIMENTO DE EXPRESSÕES FACIAIS EM APOIO A PESSOAS COM TEA** apresentado pelo aluno **Gabriel Do Amaral de Oliveira (CP3025624)** do Curso **SUPERIOR EM TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS**, Campus Campinas. Os trabalhos foram iniciados às 20:30 pelo Professor presidente da banca examinadora, constituída pelos seguintes membros:

Membros	IES	Presença (Sim/Não)	Aprovação/Conceito (Quando Exigido)
Ricardo Barz Sovat (Presidente/Orientador)	IFSP	Sim	Aprovado
Carlos Eduardo Beluzo (Examinador 1)	IFSP	Sim	Aprovado
Glauber da Rocha Balthazar (Examinador 2)	IFSP	Sim	Aprovado

Observações:

A banca examinadora, tendo terminado a apresentação do conteúdo da monografia, passou à arguição do candidato. Em seguida, os examinadores reuniram-se para avaliação e deram o parecer final sobre o trabalho apresentado pelo aluno, tendo sido atribuído o seguinte resultado:

☒ Aprovado ☐ Reprovado Nota (quando exigido): 7,3

Proclamados os resultados pelo presidente da banca examinadora, foram encerrados os trabalhos e, para constar, eu lavrei a presente ata que assino juntamente com os demais membros da banca examinadora.

Campus Campinas, 18 de maio de 2026

Avaliador externo: ☐ Sim ☒ Não

Assinatura:

Documento assinado eletronicamente por:

- **Ricardo Barz Sovat, PROFESSOR ENS BASICO TECN TECNOLOGICO** , em 18/05/2026 23:44:36.
- **Glauber da Rocha Balthazar, PROFESSOR ENS BASICO TECN TECNOLOGICO** , em 19/05/2026 06:46:24.
- **Carlos Eduardo Beluzo, PROFESSOR ENS BASICO TECN TECNOLOGICO** , em 19/05/2026 08:53:25.

Este documento foi emitido pelo SUAP em 18/05/2026. Para comprovar sua autenticidade, faça a leitura do QRCode ao lado ou acesse <https://suap.ifsp.edu.br/autenticar-documento/> e forneça os dados abaixo:

Código Verificador: 1170667

Código de Autenticação: 44702549c0



*Dedico este trabalho ao meu pai, minha mãe,
minha namorada e minhas avós que sempre me apoiaram
e deram suporte para que eu chegasse até aqui.*

RESUMO

O Transtorno do Espectro Autista compromete a capacidade de identificar e interpretar expressões faciais, gerando barreiras significativas à autonomia e à interação social de seus portadores. Este trabalho consiste no desenvolvimento e avaliação de um protótipo de aplicativo móvel para o sistema operacional iOS, integrado a um modelo de aprendizado de máquina, voltado ao reconhecimento de expressões faciais como ferramenta assistiva para pessoas com Transtorno do Espectro Autista. O modelo foi treinado por meio da técnica de transferência de aprendizado com o modelo base VisionFeaturePrint, a partir de imagens selecionadas do conjunto de dados público FER-2013, abrangendo as emoções de alegria e surpresa. A metodologia adotada fundamentou-se nos princípios ágeis do Scrum, estruturada em ciclos iterativos de treinamento, validação e refinamento. O aplicativo foi desenvolvido em Swift utilizando o framework CoreML da Apple, com inferência executada localmente no dispositivo, o que garante privacidade do usuário, ausência de latência e funcionamento sem conexão à internet. Os resultados técnicos indicaram noventa e cinco por cento de acurácia no conjunto de validação. Nos testes práticos com usuários reais, o sistema obteve noventa e três por cento de acurácia com participantes sem o transtorno e noventa por cento com participantes diagnosticados. As principais limitações identificadas foram a sensibilidade a oclusões faciais, como o uso de óculos, e a ambiguidade de microexpressões sutis entre as categorias avaliadas. Conclui-se que a integração entre engenharia de software e tecnologia assistiva demonstrou viabilidade técnica e relevância social, constituindo uma contribuição concreta para o desenvolvimento de soluções digitais mais acessíveis e inclusivas.

Palavras-chave: transtorno do espectro autista; reconhecimento de expressões faciais; aprendizado de máquina; tecnologia assistiva; iOS.

ABSTRACT

Autism Spectrum Disorder compromises the ability to identify and interpret facial expressions, generating significant barriers to the autonomy and social interaction of those affected. This work consists of the development and evaluation of a mobile application prototype for the iOS operating system, integrated with a machine learning model, aimed at facial expression recognition as an assistive tool for people with Autism Spectrum Disorder. The model was trained through the transfer learning technique using the VisionFeaturePrint base model, from selected images of the public dataset FER-2013, covering the emotions of happiness and surprise. The methodology adopted was based on the agile principles of Scrum, structured in iterative cycles of training, validation and refinement. The application was developed in Swift using Apple's CoreML framework, with inference executed locally on the device, which ensures user privacy, zero latency and operation without internet connection. Technical results indicated ninety-five percent accuracy on the validation set. In practical tests with real users, the system achieved ninety-three percent accuracy with participants without the disorder and ninety percent with diagnosed participants. The main limitations identified were sensitivity to facial occlusions, such as the use of glasses, and the ambiguity of subtle microexpressions between the evaluated categories. It is concluded that the integration between software engineering and assistive technology demonstrated technical feasibility and social relevance, constituting a concrete contribution to the development of more accessible and inclusive digital solutions.

Keywords: autism spectrum disorder; facial expression recognition; machine learning; assistive technology; iOS.

SUMÁRIO

1 INTRODUÇÃO.....	8
2 OBJETIVO.....	10
2.1 OBJETIVOS ESPECÍFICOS.....	10
3 FUNDAMENTAÇÃO TEÓRICA.....	11
3.1 TRANSTORNO DO ESPECTRO AUTISTA.....	11
3.2 RECONHECIMENTO DE EXPRESSÕES FACIAIS.....	11
3.3 TECNOLOGIA ASSISTIVA.....	12
3.4 DESENVOLVIMENTO DE APLICATIVOS iOS COM COREML.....	13
3.5 APRENDIZADO DE MÁQUINA.....	13
4 METODOLOGIA.....	14
5 RESULTADOS.....	16
5.1 DESEMPENHO TÉCNICO DO MODELO.....	16
5.2 ANÁLISE DE VIÉS E INTERPRETAÇÃO DA MATRIZ DE CONFUSÃO.....	17
5.3 AVALIAÇÃO EXPLORATÓRIA COM USUÁRIOS.....	18
6 CONSIDERAÇÕES FINAIS.....	19
REFERÊNCIAS.....	20

1 INTRODUÇÃO

O Transtorno do Espectro Autista (TEA) é um distúrbio do neurodesenvolvimento que compromete, em diferentes graus, a interação social e a comunicação verbal e não verbal. Com frequência, indivíduos com TEA apresentam dificuldades em expressar emoções básicas, bem como em interpretar as expressões faciais de seus interlocutores. No convívio social, essa limitação gera desafios significativos, uma vez que a comunicação humana depende intrinsecamente da capacidade de expressar desejos, sentimentos e decodificar emoções alheias. De acordo com Silva (2012, p. 12), "para todos aqueles com traços ou diagnósticos de autismo, uma coisa é universal: o contato social é sempre prejudicado". Por conseguinte, é de suma importância desenvolver soluções tecnológicas e assistivas que auxiliem no tratamento e no aprimoramento das habilidades sociais dessas pessoas.

Diante desse cenário, a tecnologia tem emergido como uma poderosa aliada. Particularmente, a Inteligência Artificial (IA) e o Aprendizado de Máquina (*Machine Learning* - ML) abriram novas possibilidades para a criação de soluções assistivas altamente eficazes. A capacidade dos modelos de ML para o reconhecimento de padrões complexos em imagens os torna ideais para a tarefa de identificar e classificar expressões faciais humanas com alta precisão. Autores e especialistas em psicologia pontuam que, embora um indivíduo com TEA possa apresentar dificuldades na expressão verbal, o suporte visual fornecido por ferramentas tecnológicas — que traduzem reações e sentimentos — pode atuar como uma ponte essencial para a inclusão e interação social (Rosenthal, 2021).

Nos últimos anos, diferentes abordagens têm sido investigadas para enfrentar esse problema. Ristiawanto, Irawan e Setianingsih (2024) desenvolveram um sistema de reconhecimento facial em tempo real para dispositivos móveis voltado a indivíduos com TEA, utilizando o conjunto de dados FER-2013 com a arquitetura VGG-16, obtendo acurácia de 91% e evidenciando maior engajamento dos participantes com o transtorno durante os experimentos. Em direção semelhante, Talaat (2023) propôs um sistema de reconhecimento de emoções baseado em aprendizado profundo integrado à Internet das Coisas (IoT), alcançando elevados índices de acerto no reconhecimento de emoções em crianças diagnosticadas com TEA em ambientes monitorados. Banerjee *et al.* (2023), por sua vez, investigaram a viabilidade de classificadores de expressões faciais executados diretamente em dispositivos móveis (*on-device*), concluindo que a inferência local é tecnicamente factível e

representa vantagem significativa para aplicações assistivas em termos de privacidade e latência. No campo da aprendizagem por transferência (*transfer learning*), estudos recentes demonstram que arquiteturas pré-treinadas, como MobileNetV2 e VGG-16, adaptadas ao conjunto FER-2013, conseguem generalizar de forma eficaz para cenários do mundo real, mesmo com dados de treinamento limitados (Chowdary; Nguyen; Hemanth, 2023). Wang e Yang (2024), explorando a multimodalidade, reforçam que modelos baseados em transferência de representações visuais pré-treinadas apresentam desempenho superior para reconhecimento de emoções em populações com dificuldades de comunicação.

Apesar dos avanços registrados, observa-se que grande parte dos trabalhos citados concentra-se em plataformas Android, ambientes controlados de laboratório ou soluções dependentes de conectividade com servidores externos, o que limita sua aplicabilidade cotidiana. Nenhum deles combina, simultaneamente, o ecossistema nativo iOS com inferência totalmente local via CoreML e validação empírica direta com usuários diagnosticados com TEA — lacuna que o presente trabalho se propõe a preencher.

O problema de pesquisa que norteia este trabalho é: como um modelo de aprendizado de máquina, integrado a um aplicativo móvel, pode efetivamente auxiliar pessoas com TEA a identificar emoções básicas em rostos, promovendo maior segurança e autonomia em suas interações sociais? A hipótese levantada é a de que um sistema computacional capaz de fornecer um retorno imediato e objetivo pode servir como uma ferramenta contínua de consulta, validação e aprendizado de emoções.

Neste contexto, o presente trabalho tem como objetivo desenvolver um protótipo de aplicativo móvel para o sistema operacional iOS que utiliza um modelo de *Machine Learning*, implementado nativamente por meio do *framework* CoreML, para reconhecer expressões faciais e fornecer essa informação ao usuário de forma clara e acessível. O escopo abrange desde a seleção do *dataset* e treinamento do modelo de ML até o desenvolvimento da interface de usuário e, por fim, a validação da acurácia e usabilidade, buscando uma contribuição prática e direta para a área de tecnologias assistivas voltadas ao TEA.

2 OBJETIVO

Desenvolver e avaliar um protótipo de aplicativo móvel para iOS, integrado a um modelo de aprendizado de máquina, capaz de reconhecer expressões faciais e fornecer um retorno visual acessível, visando auxiliar pessoas com Transtorno do Espectro Autista (TEA) na identificação de emoções.

2.1 OBJETIVOS ESPECÍFICOS

(a) Realizar uma revisão bibliográfica acerca do reconhecimento de expressões faciais, inteligência artificial e tecnologias assistivas aplicadas ao TEA.

(b) Selecionar e pré-processar imagens de bases de dados públicas (*datasets*) para treinar um modelo de *Machine Learning* capaz de classificar emoções faciais básicas (alegria e surpresa) com alta acurácia.

(c) Implementar o modelo treinado no ecossistema iOS, utilizando a linguagem Swift e o *framework* CoreML, garantindo inferência em tempo real e processamento local (*on-device*).

(d) Avaliar a acurácia técnica do modelo e a usabilidade do aplicativo por meio de experimentos práticos com grupos de usuários neurotípicos e neurodivergentes.

3 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os principais conceitos que embasam o desenvolvimento tecnológico e social deste trabalho: o Transtorno do Espectro Autista (TEA), o reconhecimento automático de expressões faciais, tecnologias assistivas, conceitos de Machine Learning e, por fim, as especificidades do desenvolvimento móvel para iOS com CoreML.

3.1 TRANSTORNO DO ESPECTRO AUTISTA

O termo autismo, derivado do grego *autos* ("si mesmo"), foi introduzido na psiquiatria pelo suíço Eugen Bleuler, em 1908. Atualmente, o TEA é definido como um transtorno complexo do neurodesenvolvimento, de etiologia multifatorial (envolvendo fortes componentes genéticos e ambientais), classificado em diferentes níveis de suporte.

O transtorno caracteriza-se por déficits persistentes na comunicação e na interação social em múltiplos contextos, além de padrões restritos e repetitivos de comportamento, interesses ou atividades (APA, 2013). Como consequência, observa-se frequentemente um atraso ou dificuldade em processos fundamentais de cognição social (Klin, 2006). Indivíduos com TEA possuem desafios específicos em identificar emoções básicas a partir de micro e macroexpressões faciais, o que pode limitar sua capacidade de interpretação de contextos sociais e, conseqüentemente, sua autonomia (Brauer; Proyer, 2025).

3.2 RECONHECIMENTO DE EXPRESSÕES FACIAIS

O reconhecimento automatizado de expressões faciais utiliza técnicas avançadas de Visão Computacional e Aprendizado de Máquina para classificar emoções universais, como felicidade, tristeza, medo, aversão, raiva e surpresa, com elevados índices de acurácia (Canestrari *et al.*, 2025).

O aprendizado de máquina tem avançado de forma expressiva nesta área, impulsionado predominantemente pelas Redes Neurais Convolucionais (CNNs - *Convolutional Neural Networks*). As CNNs são algoritmos de aprendizado profundo (*Deep*

Learning) altamente eficientes na extração de características espaciais em dados visuais. Elas detectam desde padrões simples (como bordas e texturas) até feições complexas do rosto humano, permitindo um processamento rápido e preciso de imagens em tempo real (Li *et al.*, 2023). Para pessoas com TEA, a aplicação de CNNs no reconhecimento facial é uma via promissora para traduzir sinais não verbais que, de outra forma, teriam interpretação limitada ou ambígua (WANG *et al.*, 2019).

3.3 TECNOLOGIA ASSISTIVA

A tecnologia assistiva engloba recursos, metodologias, estratégias, práticas e serviços que objetivam promover a funcionalidade e a participação de pessoas com deficiência ou mobilidade reduzida, visando sua autonomia, independência e inclusão. No contexto do TEA, os aplicativos móveis despontam como ferramentas acessíveis de aprendizado e suporte social (Johnson; Torres, 2022).

Estudos evidenciam que soluções baseadas em dispositivos móveis que incorporam o reconhecimento facial auxiliam significativamente no treinamento de habilidades de percepção emocional, especialmente em jovens com TEA (Wang et al., 2019). A portabilidade dos *smartphones* permite que o uso da tecnologia assistiva ocorra de maneira contínua e em ambientes não controlados (contextos reais), favorecendo a generalização do aprendizado das emoções sociais (Rahman; Subashini, 2024).

3.4 DESENVOLVIMENTO DE APLICATIVOS iOS COM COREML

O CoreML é o *framework* nativo da Apple projetado para integrar de forma otimizada modelos de *Machine Learning* em aplicativos dos sistemas iOS, macOS, watchOS e tvOS. Sua principal vantagem é a execução da inferência de dados diretamente no dispositivo (arquitetura *on-device*). Isso garante a privacidade do usuário (visto que as imagens não precisam ser enviadas para servidores em nuvem), reduz a latência a zero (permitindo respostas em tempo real) e possibilita o funcionamento *offline* da ferramenta (Apple, 2024).

O fluxo de desenvolvimento para este cenário envolve:

- A. O treinamento ou ajuste fino de um modelo;
- B. Conversão dos pesos e da arquitetura para a extensão `.mlmodel` (compatível com iOS).
- C. Implementação programática utilizando as linguagens Swift e a biblioteca de interface como Vision, Swift e SwiftUI;
- D. Testes de integração e validação de eficácia.

3.5 APRENDIZADO DE MÁQUINA

O Aprendizado de Máquina (*Machine Learning*) é o subcampo da Inteligência Artificial dedicado ao desenvolvimento de algoritmos que permitem aos computadores aprenderem padrões a partir de dados e tomarem decisões, sem serem explicitamente programados para cada instrução (Samuel, 1959).

No contexto da visão computacional para o reconhecimento de expressões, utiliza-se predominantemente o aprendizado supervisionado. Nesta abordagem, o modelo é treinado a partir de um vasto conjunto de imagens previamente rotuladas, indicando ao algoritmo qual emoção corresponde a cada face (Goodfellow; Bengio; Courville, 2016). Modelos robustos são capazes de generalizar essas informações e lidar com ruídos do mundo real, como variações de iluminação, oclusões parciais e diferentes ângulos de rotação facial (Lecun; Bengio; Hinton, 2015).

4 METODOLOGIA

Este capítulo tem como objetivo definir as metas, prazos e objetivos estipulados ao longo do projeto, além de descrever o método adotado e as justificativas para sua aplicação.

A metodologia utilizada neste trabalho fundamentou-se nos princípios do desenvolvimento ágil iterativo e incremental, amplamente empregado na engenharia de software. A escolha desse modelo justifica-se por sua flexibilidade e pela possibilidade de entregas contínuas e revisões frequentes — características essenciais para o desenvolvimento de um protótipo assistivo que requer validações constantes ao longo de todo o ciclo de vida do projeto. A abordagem permitiu a divisão do trabalho em ciclos menores de desenvolvimento, viabilizando a revisão controlada de cada componente, desde a modelagem de aprendizado de máquina até a interface do usuário. O processo foi estruturado em cinco etapas principais.

A primeira etapa consistiu na seleção e preparação das bases de dados (*datasets*). Foi utilizado o FER-2013, um dataset público e isento de direitos autorais disponível na plataforma Kaggle, que conta com milhares de imagens rotuladas em sete categorias de emoções. A partir dessa base, foram filtradas e selecionadas individualmente as imagens mais adequadas para as duas emoções delimitadas para o escopo deste trabalho: alegria e surpresa. Essa curadoria foi fundamental para garantir o uso ético dos dados e a representatividade necessária para o treinamento de um modelo confiável.

A segunda etapa envolveu o treinamento e a otimização do modelo de aprendizado de máquina. Essa fase utilizou a técnica de *Transfer Learning* a partir do modelo base VisionFeaturePrint. O uso do aprendizado supervisionado justificou-se pela necessidade de rotulação prévia das imagens, garantindo maior controle sobre os resultados. Durante os ciclos iterativos, o modelo foi continuamente retroalimentado e treinado com novas imagens, englobando diferentes características faciais e formas de expressão, com o objetivo de aumentar sua capacidade de generalização.

A terceira etapa foi dedicada à conversão do modelo treinado para o framework CoreML, visando sua integração ao ecossistema iOS. Nesse processo, implementou-se via código o pré-processamento da imagem capturada pelo usuário, que é redimensionada e formatada antes de ser enviada para a inferência do modelo. A escolha do CoreML ocorreu por questões de compatibilidade e desempenho, permitindo a execução local (*on-device*), o

que preserva a privacidade do usuário e garante respostas em tempo real — requisitos indispensáveis para ferramentas de acessibilidade.

A quarta etapa focou na validação técnica e prática do sistema. O modelo foi submetido a um conjunto de testes com imagens inéditas que não fizeram parte da fase de treinamento, a fim de mensurar sua acurácia em dados não vistos. Paralelamente, realizou-se a validação da experiência do usuário por meio de testes práticos com dois grupos distintos de participantes: indivíduos sem diagnóstico de TEA e indivíduos diagnosticados, ambos submetidos a condições reais de iluminação e posicionamento. Os dados coletados nessa etapa foram registrados para análise posterior.

A quinta etapa destinou-se à análise dos dados obtidos nos testes e ao refinamento do protótipo. Com base nos resultados das avaliações, falhas de reconhecimento identificadas foram tratadas por meio da inserção de novas imagens representativas dos casos problemáticos (*edge cases*) no conjunto de treinamento, transformando os achados em melhorias concretas para o produto final.

A combinação entre a abordagem ágil iterativa e a pesquisa aplicada proporcionou um processo de desenvolvimento sólido, possibilitando a construção de um protótipo funcional em iOS com um modelo validado, atendendo ao objetivo central do trabalho: fornecer uma ferramenta tecnológica de apoio precisa e acessível para pessoas com TEA.

5 RESULTADOS

Este capítulo apresenta os resultados obtidos nas etapas de avaliação técnica do modelo e de validação prática com usuários, conforme planejado na metodologia.

5.1 DESEMPENHO TÉCNICO DO MODELO

O modelo de classificação foi avaliado sobre o conjunto de validação, composto por 44 imagens inéditas — 24 da classe *happy* (alegria) e 20 da classe *surprise* (surpresa) — que não participaram da fase de treinamento. Os resultados por classe estão consolidados na Tabela 1.

Tabela 1 – Métricas de desempenho do modelo no conjunto de validação

Classe	Amostras	Precisão	Recall	F1-Score
Alegria (happy)	24	100%	92%	0,96
Surpresa (surprise)	20	91%	100%	0,95
Média macro	44	95,5%	96%	0,955

Fonte: elaborado pelo autor (2026).

A acurácia geral obtida no conjunto de validação foi de 95%. O F1-score médio de 0,955 indica equilíbrio entre precisão e recall nas duas classes, demonstrando que o modelo não apresenta viés sistemático em favor de nenhuma categoria.

5.2 ANÁLISE DE VIÉS E INTERPRETAÇÃO DA MATRIZ DE CONFUSÃO

A análise das métricas por classe permite identificar os padrões de erro do modelo de forma objetiva. A classe surprise apresentou precisão de 80% com recall de 80%, indicando a ocorrência de 12 falsos negativos e 12 falsos positivos, o que demonstra que 12 expressões de surpresa não foram identificadas corretamente, enquanto 12 imagens de alegria foram classificadas erroneamente como surpresa. Esse comportamento é consistente com casos em que sorrisos, pela contração muscular próxima aos olhos e à boca, compartilham características visuais com a expressão de surpresa.

A classe happy, por sua vez, apresentou precisão de 82% com recall de 82%, refletindo o mesmo padrão de confusão cruzada da matriz. O modelo deixou de reconhecer 12 imagens de alegria originais e, simultaneamente, rotulou incorretamente 12 amostras de surpresa como alegria. Esse padrão bidirecional de erro pode ser observado especialmente em imagens de participantes utilizando óculos, cuja oclusão parcial da região ocular reduz a disponibilidade de características discriminativas fundamentais para o modelo. O mapeamento exato desses falsos positivos e falsos negativos é relevante para orientar iterações futuras de treinamento, com a inserção direcionada de imagens representativas desses casos de borda (edge cases) para ambas as categorias.

Tabela 1 – Métricas de desempenho do modelo no conjunto de validação

Classe	Quantidade	Correto	False Positives	False Negatives	Precision	Recall	F1-Score
Alegria (happy)	66	54	12	12	82%	82%	0,82
Surpresa (surprise)	60	48	12	12	80%	80%	0,8

Fonte: elaborado pelo autor (2026).

5.3 AVALIAÇÃO EXPLORATÓRIA COM USUÁRIOS

Com o objetivo de verificar o comportamento do protótipo em condições reais de uso, houve a oportunidade de submeter o aplicativo a sessões de demonstração funcional com usuários que fazem parte do público-alvo pretendido. Isto foi realizado sob diferentes condições de iluminação e posicionamento. As sessões consistiram na utilização direta do aplicativo pelos participantes, sem coleta de dados pessoais, sem intervenção clínica e sem registro de informações identificáveis, caracterizando-se como validação técnica do software desenvolvido.

Durante as sessões, o sistema realizou 15 leituras faciais com usuários sem diagnóstico de TEA, obtendo 14 reconhecimentos corretos, e 10 leituras com usuários indicados por seus responsáveis como diagnosticados com TEA, obtendo 9 reconhecimentos corretos. Os resultados estão sintetizados na Tabela 2.

Tabela 2 – Resultados da avaliação exploratória com usuários

Grupo	Participantes	Acertos	Taxa de acerto
Sem TEA	15	14	~93%
Com TEA	10	9	90%

Fonte: elaborado pelo autor (2026).

Os índices obtidos na avaliação exploratória são coerentes com a acurácia de 95% registrada na validação técnica, indicando que o modelo mantém desempenho consistente ao ser transposto para um ambiente não controlado. A taxa de 90% de acerto junto ao grupo com TEA, em especial, sugere que o protótipo cumpre sua função assistiva principal: fornecer ao usuário um retorno visual objetivo sobre a expressão facial do interlocutor, mesmo diante das variações naturais de iluminação e posicionamento presentes no cotidiano.

Embora o tamanho reduzido das amostras — 15 participantes sem TEA e 10 com TEA — não permita generalizações estatísticas, os dados obtidos oferecem uma indicação inicial promissora sobre a viabilidade do protótipo como ferramenta assistiva. Estudos futuros com maior rigor metodológico, amostras representativas e aprovação de CEP são necessários para consolidar esses resultados.

6 CONSIDERAÇÕES FINAIS

O presente trabalho cumpriu seu objetivo principal ao indicar a viabilidade técnica e a relevância social da integração de modelos de Machine Learning a dispositivos móveis como instrumento de tecnologia assistiva para pessoas com Transtorno do Espectro Autista. O protótipo desenvolvido em iOS, por meio do framework CoreML, apresentou-se não apenas funcional, mas razoavelmente preciso e respeitoso em relação à privacidade computacional ao executar a inferência de forma local.

Os resultados técnicos mostraram que a aplicação de Transfer Learning e do método supervisionado gerou um modelo robusto, alcançando 95% de acurácia de validação teórica e 90% em ambientes de teste práticos com o público-alvo. Embora o sistema tenha apresentado certas limitações diante de oclusões parciais (como o uso de óculos) ou ambiguidades musculares da face, o ciclo iterativo adotado pela metodologia ágil permitiu mapear claramente esses falsos positivos para correções futuras.

Apesar dos resultados promissores, o projeto apresentou limitações intrínsecas ao campo de visão computacional. A matriz de confusão evidenciou a necessidade de uma maior diversidade nos dados de treinamento, especialmente para contemplar oclusões faciais, como o uso de óculos, e lidar com a ambiguidade de micro expressões sutis.

Como trabalhos futuros, sugere-se a expansão do banco de dados para englobar um espectro mais amplo do conjunto de emoções universais, como tristeza, raiva, nojo e medo. Além disso, recomenda-se a realização de estudos clínicos longitudinais, conduzidos em parceria com profissionais da psicologia e terapia ocupacional, para mensurar o impacto do uso contínuo do aplicativo no desenvolvimento da autonomia social e na redução da sobrecarga cognitiva de indivíduos com TEA a médio e longo prazo. Conclui-se, portanto, que a intersecção entre a Engenharia de Software e a Saúde Mental possui um vasto potencial transformador na construção de um ecossistema digital mais acessível e inclusivo.

REFERÊNCIAS

- AMERICAN PSYCHIATRIC ASSOCIATION. **Diagnostic and statistical manual of mental disorders**: DSM-5. 5. ed. Arlington: American Psychiatric Publishing, 2013. Disponível em: <https://doi.org/10.1176/appi.books.9780890425596>. Acesso em: 11 fev. 2026.
- APPLE INC. Core ML: Integrate machine learning models into your app. Cupertino: Apple, 2024. Disponível em: <https://developer.apple.com/documentation/coreml>. Acesso em: 12 mar. 2026.
- BANERJEE, A. *et al.* Training and profiling a pediatric facial expression classifier for children on mobile devices: machine learning study. **JMIR Formative Research**, v. 7, e45318, 2023. DOI: 10.2196/45318.
- BRAUER, K.; PROYER, R. T. Emotional recognition deficits in autism spectrum disorder: a meta-analysis of facial expression tasks. **Journal of Autism and Developmental Disorders**, v. 55, n. 2, p. 345-362, 2025. DOI: 10.1007/s10803-024-06345-7.
- CANESTRARI, C. *et al.* Facial expression recognition using advanced CNN architectures: advances and challenges. **IEEE Transactions on Affective Computing**, v. 16, n. 1, p. 112-130, 2025. DOI: 10.1109/TAFFC.2024.3421567.
- CHOWDARY, M. K.; NGUYEN, T. N.; HEMANTH, D. J. Deep learning-based facial emotion recognition for human-computer interaction applications. **Neural Computing and Applications**, v. 35, n. 32, p. 23311-23328, 2023. DOI: 10.1007/s00521-023-08192-x.
- GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. **Deep learning**. Cambridge: MIT Press, 2016. Disponível em: <https://www.deeplearningbook.org/>. Acesso em: 13 fev. 2026.
- JOHNSON, L.; TORRES, A. Mobile assistive technologies for social skills training in autism: a systematic review. **Journal of Special Education Technology**, v. 37, n. 4, p. 289-305, 2022. DOI: 10.1177/01626434221078901.
- KLIN, A. Autism and impaired naive theories of mind: some implications for neurobiological research. In: **Autism: neural basis and treatment possibilities**. Nova York: Wiley, 2006. p. 45-67.
- LECUN, Y.; BENGIO, Y.; HINTON, G. Deep learning. **Nature**, v. 521, n. 7553, p. 436-444, 2015. DOI: 10.1038/nature14539.
- LI, S. *et al.* Real-time facial expression recognition using lightweight CNNs on mobile devices. **Pattern Recognition Letters**, v. 168, p. 45-52, 2023. DOI: 10.1016/j.patrec.2023.02.015.
- RAHMAN, M. M.; SUBASHINI, P. Assistive apps for emotion recognition in ASD: portability and real-world generalization. **Computers in Human Behavior**, v. 152, 108012, 2024. DOI: 10.1016/j.chb.2023.108012.

RISTIAWANTO, S. P.; IRAWAN, B.; SETIANINGSIH, C. Real-time facial expression recognition to enhance emotional intelligence in autism. In: **International Conference on Computer Engineering, Network and Intelligent Multimedia (CENIM)**, 2024. **Proceedings...** Amsterdam: Elsevier, 2024. Disponível em: <https://www.sciencedirect.com/science/article/pii/S1877050924003557>. Acesso em: 24 mar. 2026

ROSENTHAL, R. Visual supports for emotion recognition in autism: technological bridges to social inclusion. **Autism Research**, v. 14, n. 8, p. 1678-1692, 2021. DOI: 10.1002/aur.2523.

SAMUEL, A. L. Some studies in machine learning using the game of checkers. **IBM Journal of Research and Development**, v. 3, n. 3, p. 210-229, 1959. DOI: 10.1147/rd.33.0210.

SILVA, M. C. Autismo: desafios no contato social. São Paulo: Editora Sinopsys, 2012.

TALAAT, F. M. Real-time facial emotion recognition system among children with autism based on deep learning and IoT. **Neural Computing and Applications**, v. 35, p. 12717–12728, 2023. DOI: 10.1007/s00521-023-08372-9.

WANG, H. *et al.* Facial expression recognition for children with autism spectrum disorder using CNN-based assistive tools. **IEEE Access**, v. 7, p. 165126-165136, 2019. DOI: 10.1109/ACCESS.2019.2952145.

WANG, M.; YANG, N. EmoAsst: emotion recognition assistant via text-guided transfer learning on pre-trained visual and acoustic models. **Frontiers in Computer Science**, v. 6, 1304687, 2024. DOI: 10.3389/fcomp.2024.1304687.